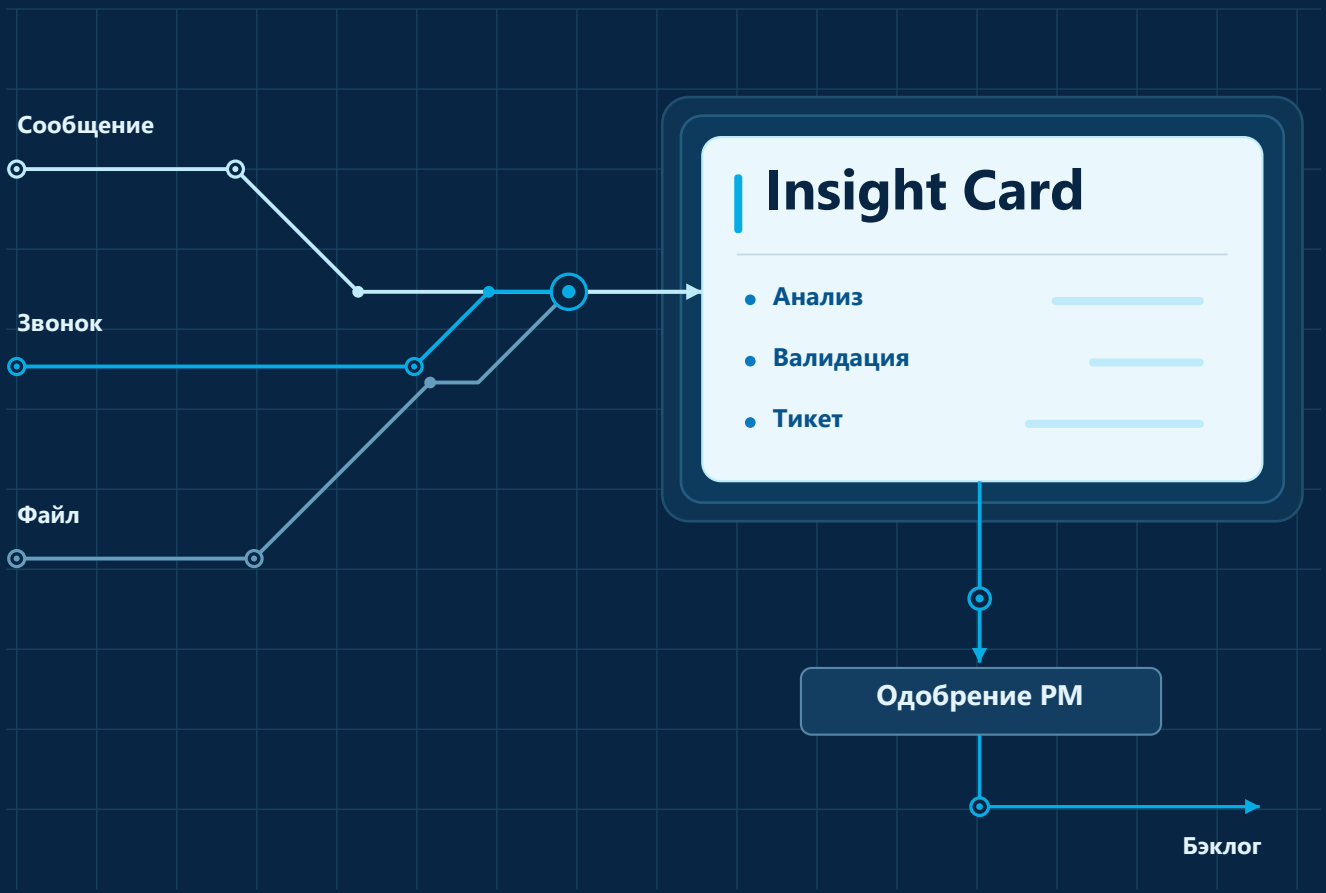
REQUESTFLOW

ИИ-агент для ретрансляции пользовательских обращений из поддержки в разработку

SIGNAL / TRACE / DECISION



Команда flying cats

Илья Матвеев, Анастасия Кабанова

00 / КОНТЕКСТ И ИССЛЕДОВАНИЕ

От обращений к продуктовой повестке

RequestFlow извлекает факты из обращений «Газпром нефти», ищет повторы и передаёт продуктовому менеджеру (PM) проверяемую Insight Card. Поддержка ведёт обращения, PM утверждает задачи.

Отраслевые аналоги

ИСТОЧНИК	ПОДТВЕРЖДЁННЫЙ ОПЫТ	Полезный опыт
SAP [1]	Кластеризация тикетов и оценка потенциальной экономии времени.	**Тема, время обработки, действие**
Dovetail [2]	Сводит B2B-обратную связь по компаниям и их значимости.	**Число и значимость компаний**
AWS Contact Lens [3]	Поиск известных категорий и новых тем.	**Known Issues / Emerging Needs**
МФТИ / ГПН [4]	Помощник Service Desk с HPSM и распознаванием терминов.	**Интеграция во внутренний ИТ-контур**
Яндекс Такси [10]	Модель-критик сверяет ответы с эталонными кейсами.	**Дополнительная проверка ответов ИИ**
Сбер / V Flow [11]	Правила и ИИ в Platform V Flow. Ключевые решения за сотрудниками.	**Human-in-the-Loop и контроль прав**

Papadia et al. искали темы в транскриптах энергосбыта [9].

Анализ обращений организован в двух контурах. **Known Issues** сопоставляет новые сообщения с уже известными проблемами и задачами бэклога, предотвращая дублирование. **Emerging Needs** выявляет повторяющиеся пожелания и неудобства, которые ещё не отражены в продуктовой повестке.

Known Issues и Emerging Needs



Семь категорий обращений охватывают дефекты (`defect`), запросы новых функций (`feature_request`), неудобства интерфейса (`usability`), вопросы использования (`how_to`), операционные запросы (`operational_request`), управление доступом (`access`) и прочее (`other`). Несколько меток помогают отличать в одном обращении дефекты, пожелания и вопросы для поддержки.

01 / АРХИТЕКТУРА И БИЗНЕС-ПРОЦЕСС

Логическая схема RequestFlow

Три прикладных сервиса · внутренний контур



01 / АРХИТЕКТУРА И БИЗНЕС-ПРОЦЕСС

Трассировка обращения «Вебнефть»

Демонстрационная Insight Card

Кнопка «Далее» на втором шаге

`needs_review`

НАБЛЮДЕНИЕ

«На втором шаге оформления договора не реагирует кнопка “Далее”».

`defect` тикет

ИСТОЧНИК

Кейс · «Вебнефть» · `source_id`

Период и N предстоит измерить.

ГИПОТЕЗА

Причина не установлена (`null`).

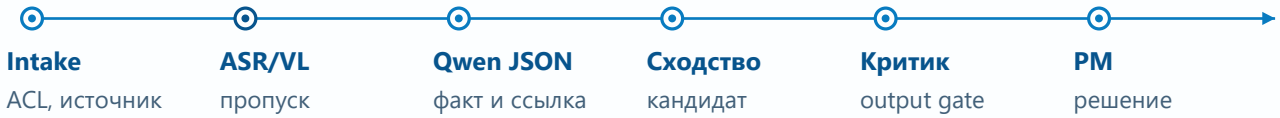
СЛЕДУЮЩИЙ ШАГ

Проверить связь с известной темой или завести кандидата на новую.

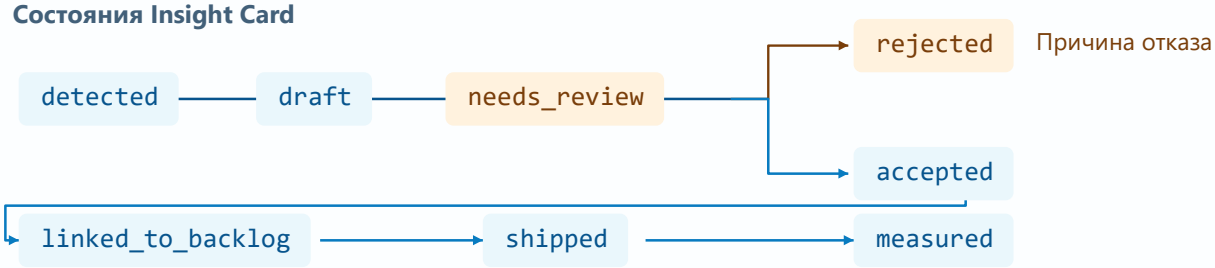
РЕШЕНИЕ PM

Принять **Отклонить** **Объединить**

TRACE · ПУТЬ ТЕКСТОВОГО ТИКЕТА



Состояния Insight Card



Контракт карточки. `theme_id`, продукт, категория, `observed_problem` и отдельно `hypothesized_root_cause`, N обращений и M организаций за период, тренд, приоритет, `source_id`, цитата или таймкод, следующий шаг, владелец и журнал. При отсутствии `org_id` M скрываем. Вес клиента допустим только при разрешённых данных.

Приоритет учитывает охват, частоту, динамику, критичность сценария и подтверждённый бизнес-контекст. PM калибрует коэффициенты. Trace фиксирует версии модели и промпта, инструменты, источники и переходы без PII. Отказ пополняет разметку без автодообучения.

02 / TOOLS И ЭКСПЛУАТАЦИЯ

Инструменты, права и нагрузка

Сервис проверяет аргументы и права. У модели нет прямого SQL и произвольного HTTP.

ГРУППА	ТИПИЗИРОВАННЫЙ TOOL	ПРАВА И ГРАНИЦЫ

Read	`list_updated_tickets(cursor,limit)`
	`get_ticket(ticket_id)`
	`get_attachment(ref)`
	`get_product_taxonomy(product_id)`
	`get_existing_backlog_items(product_id)`
	`get_account_context(org_id)`
		Чтение без изменения и удаления, по ACL пользователя и сервисного аккаунта. get_account_context требует дополнительных прав.

Perception	`transcribe_call(ref)` `extract_image_facts(ref)`	Текст, аудио и изображения обрабатывают внутренние модели.

Analytics	`find_similar_issues(product_id,issue)`
	`aggregate_theme(theme_id,period)`
	`draft_insight(theme_id)`
	`validate_insight(insight_id)`
	`submit_for_review(insight_id)`
	`record_reviewer_decision(...)`
		Поиск, группировка и черновики. Запись в реестр кандидатов и аудит. Решение за PM.

Write **PM only**	`create_backlog_item(insight_id)`	Запись в трекер после одобрения PM. Сервер проверяет роль, статус accepted и идемпотентность.

Нагрузка и ориентиры SLA

Сценарий: 460 × 22 рабочих дня = **10 120 в месяц**. При потоке в выходные считаем по календарю.

При N = 460/сутки: p_a = 20% со звонком, d_a = 3 мин, p_i = 10% с 1 изображением, q = 1 вызов.

Qwen-ASR
`N × p_a × d_a`
276 мин аудио/сутки
Диапазон 264–288 мин

Qwen-VL
`N × p_i`
46 изображений/сутки
Диапазон 44–48

Qwen 3.8
`N × q + K × q_c`
460 осн. вызовов/сутки
Плюс вызовы по новым темам

На пилоте измерим число новых тем K и число вызовов q_c на сборку и проверку каждой темы.

ЧЕТЫРЕ ИНТЕРВАЛА

Инференс, обработка тикета, подготовка карточки после подтверждения повтора, ожидание решения PM.

ЧТО ИЗМЕРЯЕМ НА ПИКЕ

p50/p95 времени, размер и возраст очереди, аудиоминуты ASR за минуту работы, токены Qwen/с и доля ошибок.

> Очередь сглаживает пики. После лимита повторов сбои уходят в DLQ на ручной разбор. Цели SLA согласуем по замерам пилота.

03 / ПРОМПТ И БЕЗОПАСНОСТЬ

Промпт, JSON и границы доверия

Семь секций Аналитика

01	ROLE	Извлечь сигнал. Ответ клиенту вне роли.
02	TRUST_BOUNDARY	Тикет и вложения — недоверенные данные.
03	INPUT	ID, контекст с ACL, источник и таймкод.
04	CLASSIFICATION	Несколько меток. Факт и гипотеза раздельно.
05	GROUNDING	Только проверяемые цитаты.
06	OUTPUT	Строгий JSON.
07	QUALITY_GATE	`needs_review=true` при нехватке фактов.

JSON · ДЕМОНСТРАЦИОННЫЙ ПРОФИЛЬ

```
{
  "ticket_id": "EXAMPLE-01",
  "categories": ["defect"],
  "observed_problem":
    "Кнопка «Далее» не реагирует",
  "hypothesized_root_cause": null,
  "evidence": [{
    "source_id": "EXAMPLE-01",
    "span_or_timestamp": "не реагирует"
  }],
  "needs_review": true,
  "uncertainty_reason":
    "Причина неизвестна"
}
```

EXAMPLE-01 · синтетический ID

Шесть принципов безопасности RequestFlow

01 Least Privilege

Тикеты доступны на чтение. Сервисным аккаунтам выдаём минимум прав. Доступ проверяем по ACL/RBAC.

02 Защита от Prompt Injection

Текст, транскрипты и файлы недоверенны. TRUST_BOUNDARY отделяет их от инструкций. Input Guardrail и ограничения tools снижают риск [8].

03 Недоверенный результат LLM

Код проверяет JSON Schema, источники, права и PII. Критик на Qwen 3.8 проверяет новые и спорные карточки с указанием причины.

04 Риск Lethal Trifecta

Блокируем произвольный внешний HTTP и egress, ограничиваем tools и запись. Это снижает риск утечки [12].

05 Human-in-the-Loop

Уполномоченный PM утверждает задачу и приоритет. Сервер проверяет решение перед записью в трекер.

06 Retention и аудит

Исходники хранятся год. Производные, кеши и логи удаляем по TTL, согласованному с ИБ. В аудите — ID, статусы, версии промптов, итоги проверок и минимум PII.

Полный промпт с комментариями прилагается отдельным .md-файлом.

04 / QA И ЭКСПЛУАТАЦИЯ

Тестирование, приёмка и выпуск

Gold set собираем из разрешённой истории до 12 месяцев по продуктам, классам, аудио и вложениям. Часть выборки размечают два эксперта независимо. Для replay делим данные по времени, исключаем общие цепочки между train/test и будущие статусы бэклога.

Путь до релиза

Gold set
Обследование и baseline

Time split
Границы по времени

Offline replay
Проверка на истории

Shadow mode
2–4 недели

Пилот
1–2 продукта, PM review

Масштабирование
После приёмки

Предлагаемые пороги пилота

Классификация	macro-F1 ≥ 0,85 по экспертной разметке
Совпадение тем	precision ≥ 0,90 и recall ≥ 0,80. Ошибки merge/split считаем отдельно.
Новые темы	Recall@K ≥ 0,80 при согласованном K
Фактическая опора	У 100% проверяемых утверждений действующий `source_id`. Критичных галлюцинаций в тестовом наборе 0.
Privacy / действия	0 успешных тестовых утечек PII и несанкционированных write-вызовов. Отдельно recall/FP маскирования.
ASR / эксплуатация	WER/CER и p95 batch latency после локального baseline. SLA согласуем с заказчиком.

АДВЕРСАРИАЛЬНЫЕ ТЕСТЫ

Ложные PII, prompt injection, межпродуктовый доступ, отсутствие источника, повторный create, отказ ASR/VL. Критика оцениваем по экспертной разметке.

RELEASE GATE

Безопасность, воспроизводимость, качество и подтверждённая полезность. Отслеживаем отказы, задержку очереди и время проверки PM.

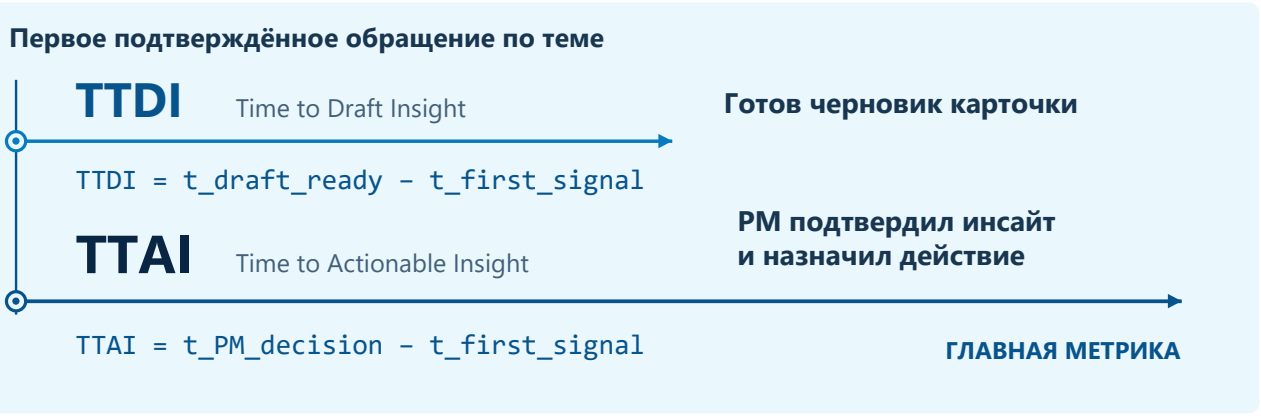
ASR timeout → ограниченный retry → очередь ошибок / ручной разбор

При сбое отключаем автопредложения. Штатный процесс поддержки сохраняется.

05 / ЭФФЕКТ ВНЕДРЕНИЯ

Метрики эффекта и наблюдаемость

TTDI И TTAI



Closed-Loop Rate

`accepted` → `linked_to_backlog` → `shipped` → `measured`

Принятые темы со связанной задачей, релизом и замером в согласованный срок / все принятые темы когорты [6] [7].

ДАННЫЕ И РАСЧЁТ

Храним `theme_id`, ID и `created_at` источников, время черновика и решения PM, версию группировки и статус. Считаем медиану и p90. Отдельно — незавершённые темы и охват ревью.

МОНИТОРИНГ

Repeat Contact Rate — повторы за период на 100 активных организаций по `org_id`. Без него считаем обращения. **PM Acceptance Rate** — принятые / рассмотренные. **Review Time** — минуты проверки PM.

BASELINE ПО ИСТОРИИ

Связываем обращения и задачи. По надёжным меткам восстанавливаем первый сигнал и подтверждение задачи. Берём статусы на дату среза.

BASELINE НАБЛЮДЕНИЕМ

Если истории мало, 2–4 недели замеряем поиск повторов, сводку, передачу PM и решение. Shadow mode идёт параллельно текущему процессу.

Эффект релиза сверяем по baseline и контролю, учитывая сезонность и изменения продукта.

Прокси для первых 2–4 недель

Evidence-Ready Rate (ERR)

```
ERR = N_validated_drafts / N_all_candidate_drafts × 100%
```

До ревью PM проверяем JSON, source_id/ACL, опору каждого факта, разделение наблюдений и гипотез и отсутствие запрещённых PII. В знаменателе все кандидаты, включая отклонённых. Сбор по событиям валидатора и экспертной выборке. Значимость оценивает PM.

Net Time Saved per Validated Insight (NTSI)

```
NTSI = median(T_manual − T_PM_review − T_correction − T_extra_support − T_extra_ops)
```

В shadow mode по сопоставимым темам замеряем ручную подготовку, ревью PM, правки, доп. работу поддержки и эксплуатации. Медиана в мин/подтверждённую тему, межквартильный размах и N. Рубли оцениваем отдельно.

06 / ФИНАНСОВАЯ МОДЕЛЬ

Экономика и порог инвестиций

460
обращений/сутки
Середина 440–480 · общий поток

644 тыс. ₽
за первый год
Сценарий модели Б

1,52 млн ₽
PV за три года
4% с 2028 · ставка 15% ном.

Прогноз ЦБ · 7,1–7,6% на конец 2026 [13], ≈4% на конец 2027–2029 [14].
ИПЦ — ориентир цены часа. ФОТ, ревью и OPEX оцениваем отдельно.

А / По сотрудникам

$$B_A = M \times h \times W \times c \times a - C_{review}$$

M — занятые анализом, h — ч экономии на человека в неделю, W — рабочих недель/год, c — стоимость часа, a — доля реализуемой экономии, C_review — доп. затраты на ревью PM/год.

Условно · M = 40 при участии всех, W = 46, C_review = 0, r_nom = 15%.

Сценарные допущения				Статичные номинальные эффекты	
Сценарий	**h, ч/нед**	**c, ₽/ч**	**a**	**B_A, ₽/год**	**PV_3, млн ₽**
Осторожный	0,5	1 000	50%	**460 000**	**1,05**
Базовый	1,5	1 200	70%	**2 318 400**	**5,29**
Оптимистичный	3	1 400	85%	**6 568 800**	**15,00**

Б / По общему потоку

$$B_B = (N \times D \times p \times \Delta t / 60) \times c \times a - C_{review}$$

N = 460/сутки — середина диапазона организаторов. Допущения · D = 250 рабочих дней/год, p = 20% подходящих обращений, Δt = 3 мин экономии, c = 800 ₽/ч, a = 70%, C_review = 0.

$$460 \times 250 \times 0{,}20 \times 3 / 60 \times 800 \times 0{,}70 = 644\,000\ ₽/год$$

А и Б — один эффект. Для 4,6 млн ₽/год нужны p = a = 100% при прочих равных.

Чувствительность Б · по одному параметру, тыс. ₽/год

N 440–480 → 616–672 · p 10–30% → 322–966 · Δt 2–4 мин → 429–859

ИНДЕКСАЦИЯ ЦЕНЫ ЧАСА НА 4% С 2028 ГОДА

$B_{2027} = 644\,000\ ₽$ · $B_{2028} = 644\,000 \times 1{,}04 = 669\,760\ ₽$

$B_{2029} = 669\,760 \times 1{,}04 = 696\,550{,}40\ ₽$

$PV_3 = 644\,000/1{,}15 + 669\,760/1{,}15^2 + 696\,550{,}40/1{,}15^3$
$= 1\,524\,428\ ₽$ · Без индексации $644\,000 \times \Sigma\ 1/(1{,}15)^t = 1\,470\,397\ ₽$

$PV_3 = \Sigma\ B_t / (1+r_{nom})^t,\ t = 1..3$ · $I_0 \le PV_3$

$(1 + r_{nom}) = (1 + r_{real}) \times (1 + \pi)$ [15]

Порог чистого эффекта — 1,314–1,752 млн ₽/год. Задержка и ревью снижают PV. Ручной VoC, правила, RequestFlow. Считаем прирост к лучшей альтернативе.

06 / ИТОГ И ИСТОЧНИКИ

Заключение и источники

RequestFlow выявляет повторяющиеся потребности в обращениях и передаёт их продуктовым командам. Три сервиса масштабируются независимо. Выводы проверяются по источникам, решения утверждает PM. На пилоте измеряем эффект в сравнении с альтернативами.

Аналоги и методика

[1] SAP — Ticket Clustering

[2] Dovetail — B2B-аналитика

[3] AWS — Contact Lens

[4] МФТИ — Service Desk

[5] Sentence-BERT

[6] Thematic / Atlassian

[7] Productboard — Insights

[8] OWASP — Prompt Injection

[9] Papadia et al. — Topic Modeling

[10] Яндекс Такси — ИИ в поддержке

[11] СберТех — Platform V Flow

[12] Simon Willison — Lethal Trifecta

Макроэкономика и NPV

[13] Банк России — прогноз от 05.11.2026

[14] Банк России — ДКП 2027–2029

[15] ВК-477 — оценка инвестпроектов, разд. 9–11