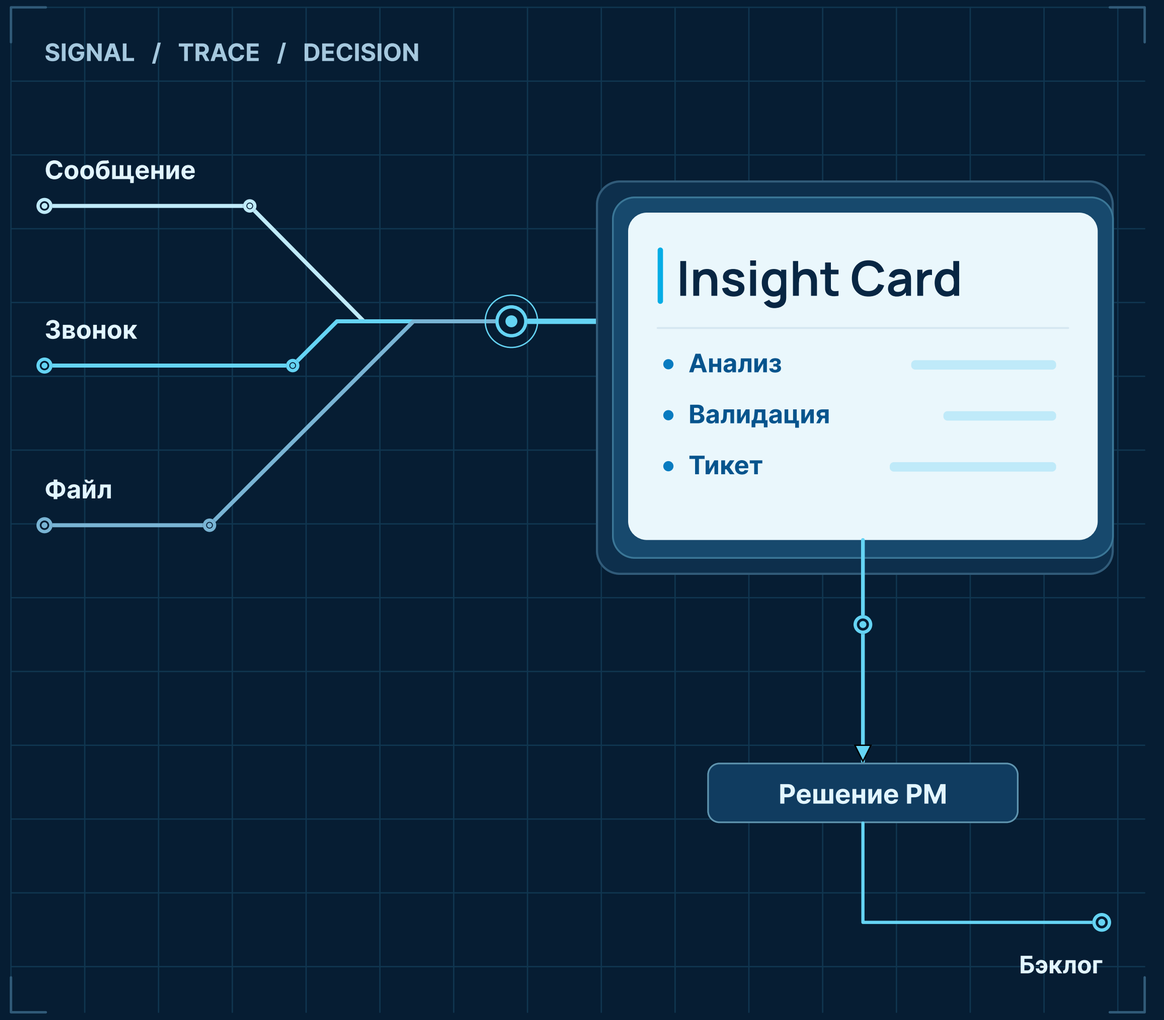
RequestFlow

От обращений пользователей к подтверждённым продуктовым решениям

ИИ-агент для ретрансляции пользовательских обращений из поддержки в разработку

К контексту →



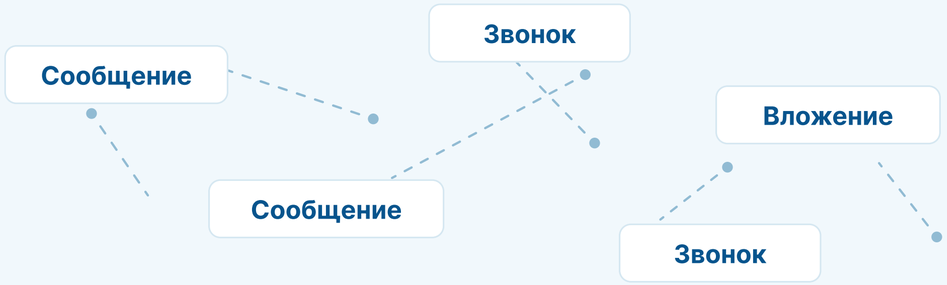
Команда flying cats

Илья Матвеев · Анастасия Кабанова

Поддержка видит отдельные обращения. Продукту нужен повторяющийся сигнал

СЕЙЧАС / РАЗРОЗНЕННЫЕ СИГНАЛЫ

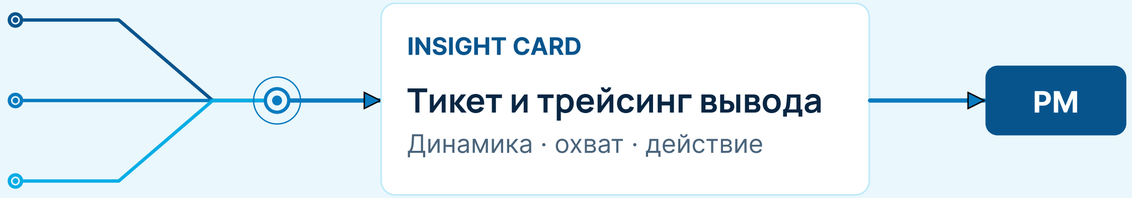
Повторяющиеся некритичные пожелания теряются в потоке



Масштаб, динамика и значимость темы остаются неясными.

RequestFlow / Анализ запросов и валидация

PM получает масштаб, источники и следующий шаг



Продуктовая команда получает готовый к проверке инсайт с доказательствами — без изменения привычного процесса поддержки.

КОНТЕКСТ

≈40
менеджеров поддержки

1 год
хранение в тикет-системе

Qwen
внутренние модели

≈460
обращений в сутки
Диапазон 440–480

На чём основан RequestFlow

Отраслевые практики дают методы группировки, проверки и передачи сигнала в продукт.

ФАКТ

ИСТОЧНИК	ПОДТВЕРЖДЁННАЯ ПРАКТИКА	ЧТО ПЕРЕНОСИМ
SAP [1] Публикация ↗	Кластеризация 2 300+ тикетов. 73 запроса · 249 ч потенциально устранимого труда.	**Группировка тем и оценка трудозатрат**
Dovetail [2] Публикация ↗	Единый анализ B2B-обращений. 35 000+ тикетов в месяц, пять команд.	**Охват организаций и контекст сегментов**
AWS Contact Lens [3] Публикация ↗	Распознавание известных категорий и обнаружение неизвестных тем.	**Два контура детекции**
МФТИ / ГПН [4] Публикация ↗	Внутренний помощник Service Desk. Интеграция HPSM и извлечение сущностей (NER).	**Интеграция внутри корпоративного контура**

ПРИНЦИП

Проверяемый VoC-сигнал

01 Повторяемость

02 Охват

03 Доказательства

[5] Papadia et al. ↗ Тематизация 993 транскрипций энергетического контакт-центра.

Два контура анализа: Known Issues и Emerging Needs

Оба контура используют один нормализованный профиль обращения и общий реестр.



ПРИОРИТЕТ ТЕМЫ Охват, динамика, частота, критичность сценария и подтверждённый бизнес-контекст.

Одна тема может иметь несколько категорий обращения.

Интерфейс аналитика: контроль, прозрачность и обратная связь

Демонстрация интерфейса на примере текстового тикета «Вебнефти»

ДЕМО

01 / ИСТОЧНИК

«На втором шаге оформления договора не реагирует кнопка „Далее“».

Тикет | Вебнефть

EVIDENCE

Цитата из официального кейса.
Доступ к исходнику проверяет ACL.

Проверка источника ↗

RequestFlow / Продуктовая аналитика

Режим демонстрации

ПРОДУКТ
Вебнефть

КОНТУРЫ
Все инсайты
Known Issues
Emerging Needs

СТАТУС
На проверке

02 / АНАЛИЗ

Прозрачный лог обработки: Qwen JSON → поиск по базе знаний и бэклогу → Критик

Трассировка ↗

Кнопка «Далее» на втором шаге

defect | needs_review | Поиск совпадения с задачей · на проверке

НАБЛЮДЕНИЕ
Кнопка не реагирует при оформлении договора.

ГИПОТЕЗА
Причина неизвестна.
Нужна проверка сценария.

Число обращений и организаций появится после проверки данных.

03 / РЕШЕНИЕ PM

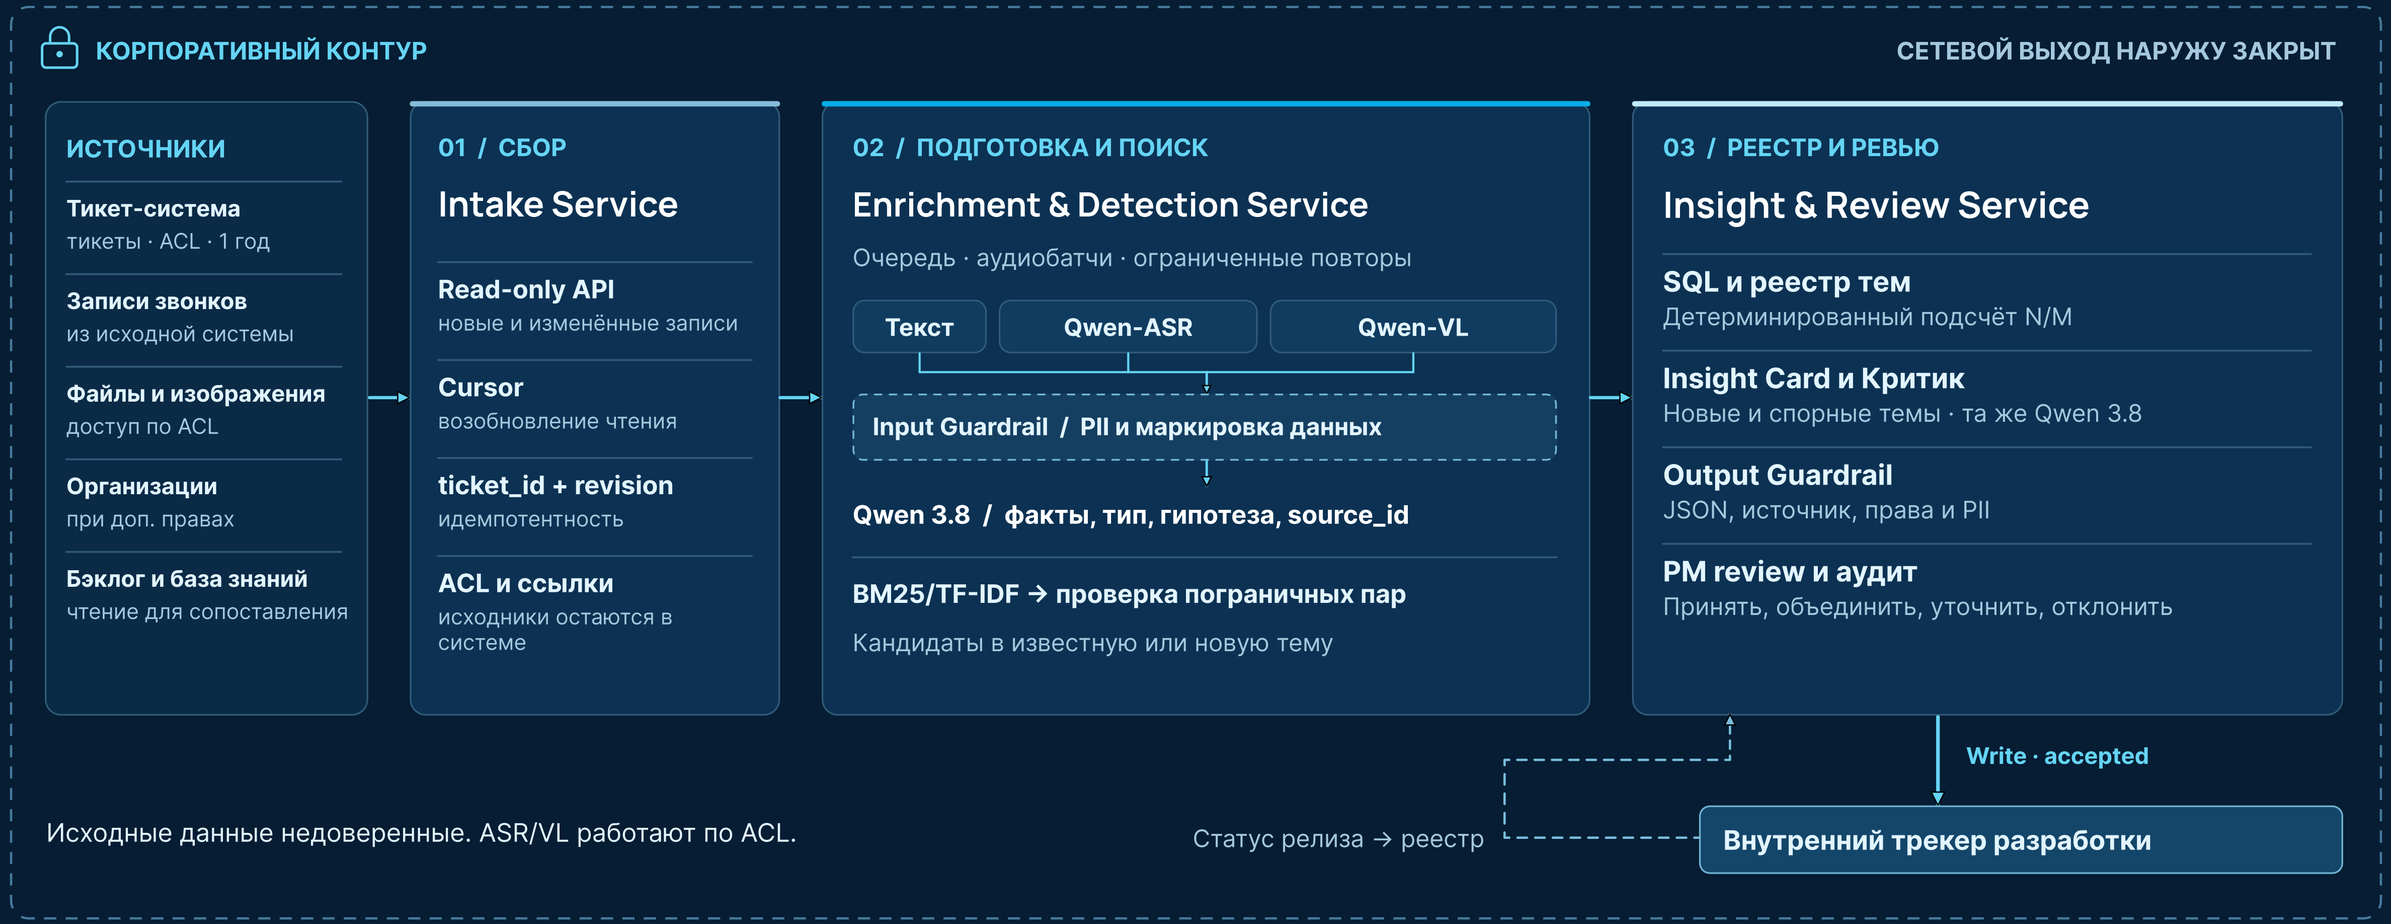
Принять | Объединить с темой | Отклонить | Отправить на уточнение

Новая задача создаётся только после одобрения PM.

Коррекции PM → датасет обратной связи → возможное дообучение модели.
В MVP — реестр, анализ ошибок и разметка.

Три сервиса от сбора до решения

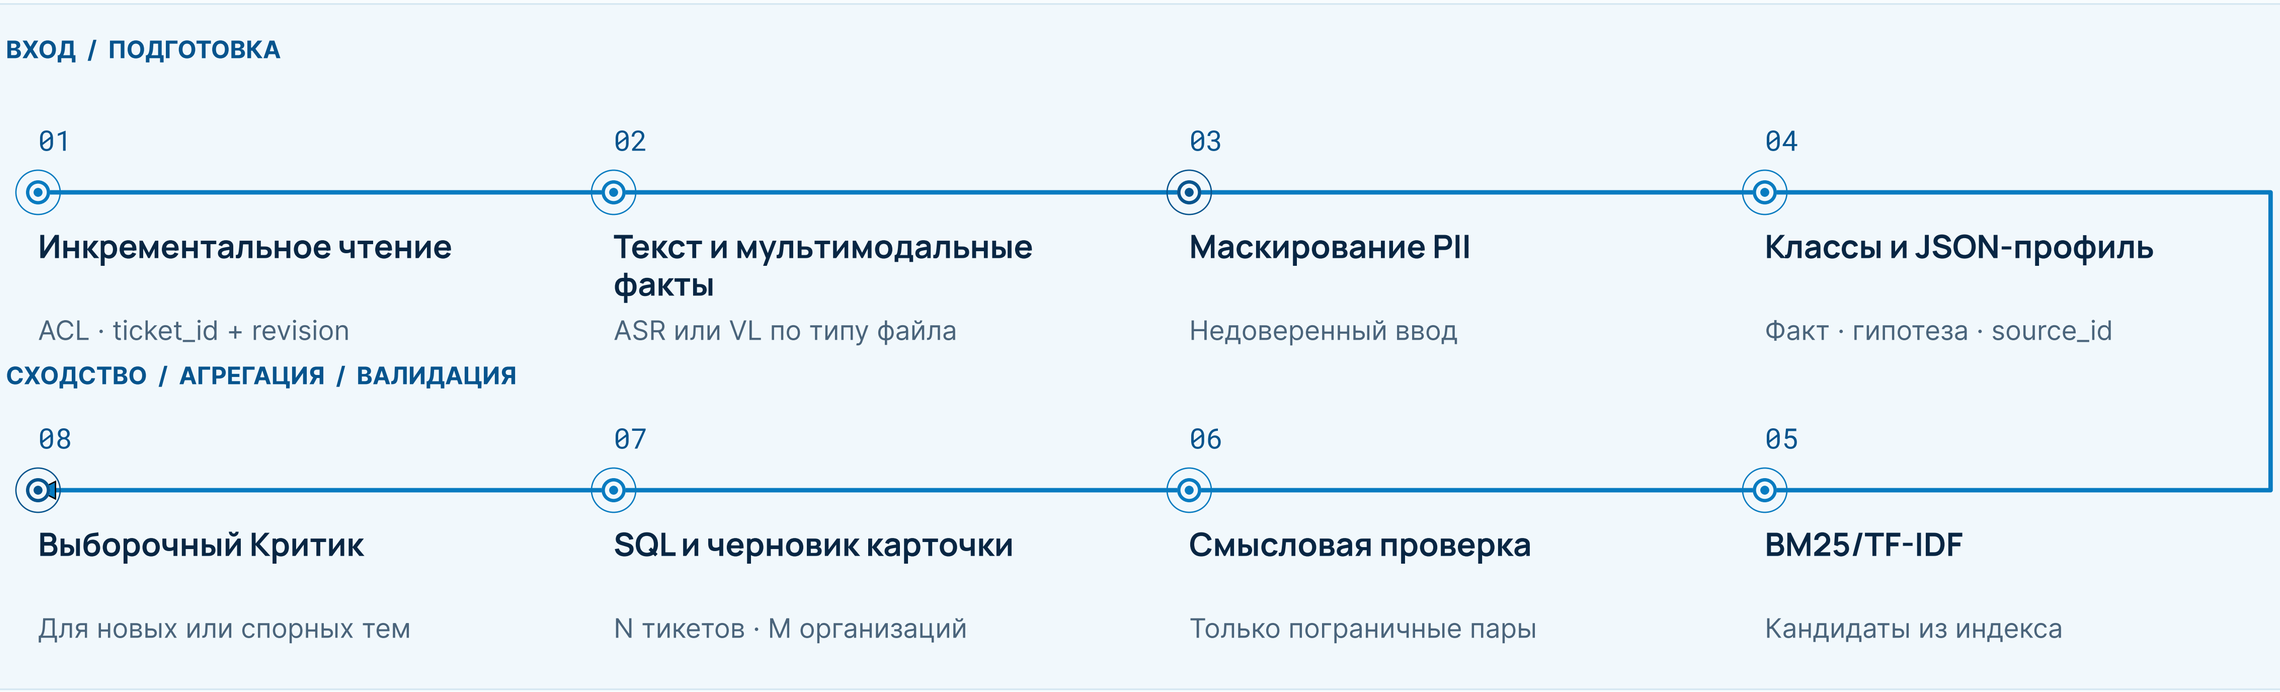
Развёртывание во внутреннем контуре ГПН: модели Qwen, действующие права доступа и контролируемые интеграции.



- Без внешних LLM и API
- Интеграция с действующей тикет-системой и бэклогом
- Адаптация к политике ИБ заказчика

Модель извлекает факты, SQL считает масштаб

Индекс сужает поиск, а Qwen 3.8 проверяет только пограничные совпадения.



Попарная проверка LLM

Число сравнений растёт квадратично с количеством тикетов.

Лексический индекс → Qwen для спорных пар

Частоты и уникальные организации считает детерминированный код.

[6] Sentence-BERT ↗ Эмбеддинги — опция после согласования ресурсов.

При отсутствии org_id показатель M скрывается.

Нагрузка зависит от реального потока

Общий поток — 440–480 обращений в сутки. Расчётная точка — 460.
В поддержке около 40 менеджеров.

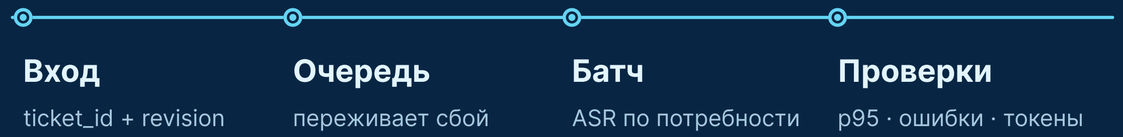
РАСЧЁТ СУТОЧНОЙ НАГРУЗКИ

Qwen-ASR	$N \times p_a \times d_a$ 460 × 0,20 × 3	276 мин/сутки Диапазон 264–288
Qwen-VL	$N \times p_i$ 460 × 0,10	46 изображений/сутки Диапазон 44–48
Qwen 3.8	$N \times q + K \times q_c$ N = 460, q = 1	460 основных/сутки + вызовы по темам

Допущения: p_a = 20% с аудио, d_a = 3 мин в среднем, p_i = 10% с изображением.
q = 1 основной вызов на обращение.

K — новые и спорные темы, q_c — вызовы на тему.
Оба параметра измеряем на пилоте.

ОБРАБОТКА И КОНТРОЛЬ ОЧЕРЕДИ



ПРИ СБОЕ

Retry → очередь ошибок → ручной разбор

ASR/VL: отмечаем неполноту данных. Qwen: ставим выпуск черновиков на паузу. Исходники и поддержка остаются доступны.

Мониторинг: p95, размер и возраст очереди, скорость ASR, токены/с и ошибки.
SLA согласуем по итогам нагрузочного теста и пилота.

СЦЕНАРИЙ **460 × 22 = 10 120 обращений за 22 рабочих дня**

При потоке в выходные используем фактический календарь.

276 мин аудио/сутки **46 изображений/сутки** **460 базовых вызовов LLM/сутки**

Расчётный сценарий. Доли медиа и параметры обработки — допущения.

Ошибки прав и обнаружение PII блокируют публикацию карточки.

Модель анализирует данные. Права и действия контролирует код

ACL / ТИПИЗИРОВАННЫЕ TOOLS

Read — **Права источника**

Тикеты, вложения, справочники, бэклог.
Контекст организации — по отдельному праву.

Analyze — **Внутри контура**

ASR/VL, поиск, агрегация SQL, черновик, валидация и ревью в реестре.

Write — **PM approval**

create_backlog_item(insight_id)
Сервер проверяет accepted, роль и повторы.

Least privilege · RBAC · журнал действий

THREAT & CONTROL DIAGRAM

НЕДОВЕРЕННЫЙ ВВОД / РИСК PROMPT INJECTION

Текст, ASR и VL по ACL → Input Guardrail: PII и маркировка данных

Аналитик / Qwen 3.8
Типизированный JSON и ссылка на фрагмент

Критик / выборочно
Сверка новых и спорных карточек с источником

Output Guardrail
JSON Schema, PII, доступность источника и права

PM approval
Человек утверждает действие. Код проверяет запись.

Как мы проектировали промпты

01 Роль Analyst
Извлекает проблему и потребность. Ответ клиенту и создание задачи вне роли.

02 Границы доверия
Тексты тикетов, записи звонков и вложения — недоверенные данные.

03 Контракт JSON
ROLE · TRUST_BOUNDARY · INPUT CLASSIFICATION · GROUNDING OUTPUT CONTRACT · QUALITY GATE
Категории, наблюдаемая проблема, потребность, гипотеза причины, доказательства, needs_review.

04 Выборочный Critic
Та же Qwen 3.8 сверяет новые и спорные карточки с исходными свидетельствами.
APPROVED / REJECTED / NEEDS_HUMAN_REVIEW с объяснением.

05 Проверка кодом
JSON Schema, права, источники, PII и запись. Решение принимает PM.

[7] OWASP LLM01:2025 ↗ Ссылки наследуют ACL. Прямой SQL и внешний HTTP недоступны модели. Производные данные удаляются по политике хранения.

Релиз проходит четыре независимые проверки

Gold Set из разрешённой истории. Временное разделение отделяет данные проверки от будущих статусов бэклога.

ПУТЬ ДО РЕЛИЗА

Обследование	Gold Set	Offline Replay	Shadow Mode	Пилот	Go/No-Go
Текущий процесс	Два эксперта	Временной split	2–4 недели	1–2 продукта	Приёмка с PM

ЦЕЛЬ ПИЛОТА

01 Качество моделей

Macro-F1 ≥ 0,85
Классификация

Precision ≥ 0,90
Совпадения

Recall ≥ 0,80
Совпадения

Recall@K ≥ 0,80
Новые темы, K согласуется

02 Доказательства

100%
Проверяемых утверждений с валидным source_id

0
Критических галлюцинаций в тестовом наборе

03 Безопасность

0
Успешных утечек PII и несанкционированных записей

Проверки
Prompt injection, ACL, повторная запись

04 Эксплуатация и PM

WER/CER · p95
После локального baseline

Пилот с PM
Подтверждённая полезность и сохранение процесса поддержки

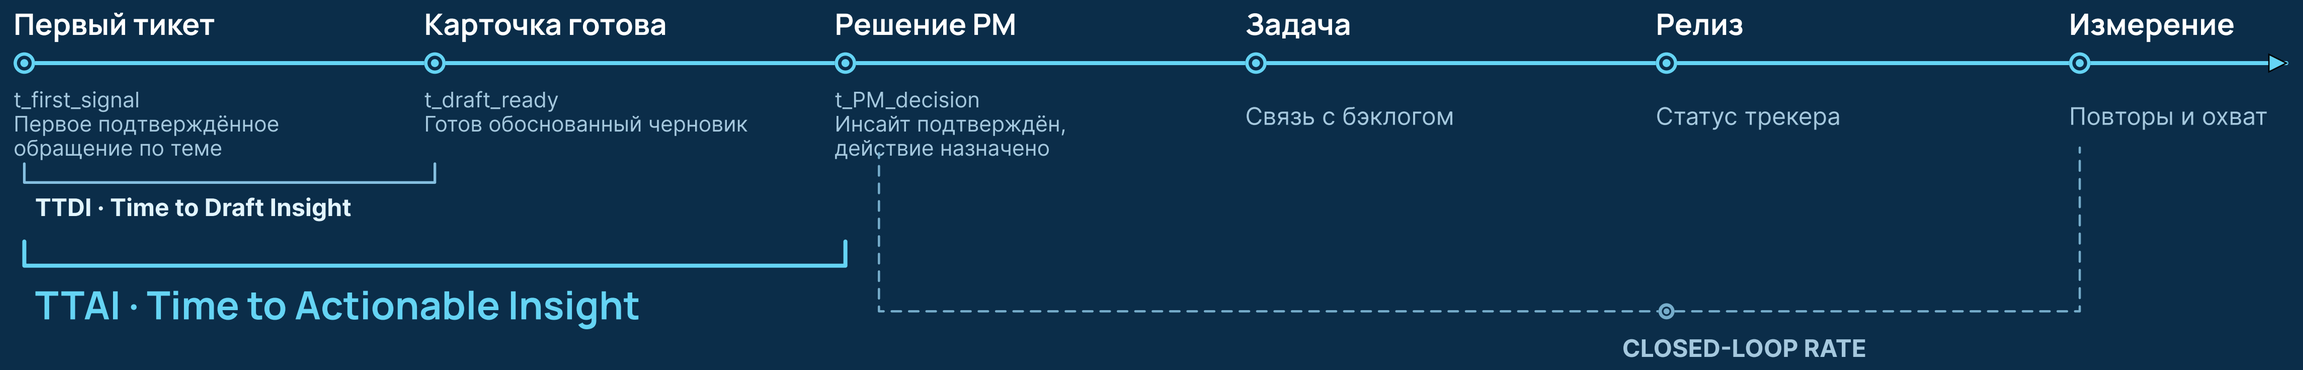
Главная метрика — время до действия PM

TTDI измеряет скорость подготовки карточки. TTAI включает её проверку и решение владельца продукта.

ОДНО НАЧАЛО / ДВЕ ДЛИТЕЛЬНОСТИ

`TTDI = t_draft_ready - t_first_signal`

`TTAI = t_PM_decision - t_first_signal`



Baseline

При наличии истории связываем тикеты и задачи по временным меткам. Иначе 2–4 недели наблюдаем текущий процесс параллельно с shadow mode. Замеряем поиск повторов, сводку, передачу PM и решение.

Показатели

Медиана и p90 для TTDI и TTAI. Незавершённые темы учитываем отдельно.
PM Acceptance Rate — принятые / рассмотренные.
Review Time — время проверки карточек PM.

Причинная оценка

Repeat Contact Rate — повторы по теме на 100 активных организаций за период. Нужен org_id. Эффект релиза проверяем относительно baseline и контроля с учётом сезонности и изменений продукта.

[8] Thematic / Atlassian ↗ [9] Productboard ↗

Closed-Loop Rate — принятые темы со связанной задачей, релизом и замером в согласованный срок / все принятые темы той же когорты.

Ранний пилот: измеряем пользу до появления устойчивой статистики

Методика прокси-метрик ↗

Evidence-Ready Rate
Доля карточек с проверенными доказательствами.

Net Time Saved per Validated Insight
Чистая экономия времени на один подтверждённо полезный инсайт.

Прокси-метрики позволяют оценить качество и операционную пользу до накопления данных для TTAI и Closed-Loop Rate.

Снижение повторов после релиза требует проверки причинности.

Пилот определит допустимый бюджет внедрения

Масштабирование начинается только после подтверждения продуктовой ценности и экономического эффекта пилота.

СЦЕНАРИЙ

СЦЕНАРИЙ	ГОДОВОЙ ЭФФЕКТ · МЛН ₽	PV ЗА 3 ГОДА · МЛН ₽
Осторожный	0,460	1,05
Базовый	2,318	5,29
Оптимистичный	6,569	15,00

`M=40 · W=46 · C_review=0 · r=15% · полный эффект с первого года`

РЕКОМЕНДАЦИЯ

Пилот на 1–2 продуктах

А · Подтверждённые трудозатраты

Измеряем труд аналитиков и время PM review.

Б · Повторные обращения

Считаем после улучшений и причинной проверки.
Каналы оцениваем раздельно.

Ручной VoC / правила / RequestFlow

В эффект относим прирост над лучшей альтернативой.

От пользовательского сигнала к проверяемому продуктовому решению



Макроэкономика: инфляция влияет на стоимость труда, расходы проекта и трёхлетний денежный поток.

ПРИЛОЖЕНИЕ 1

Чувствительность финансовой модели

ГОДОВОЙ ТРУДОВОЙ ЭФФЕКТ

$$B = M \times h \times W \times c \times a - C_{review}$$

ПОРОГ ИНВЕСТИЦИЙ · NPV ≥ 0

$$I_{max} = \Sigma\, B_t/(1+r)^t, \quad t=1..3$$

База: M=40, h=1,5 ч/нед., W=46, c=1 200 ₽/ч, a=70%, C_review=0, r=15%, эффект с 1-го года.

ИЗМЕНЯЕМ ОДНО ДОПУЩЕНИЕ / ОСТАЛЬНЫЕ ФИКСИРОВАНЫ

Вовлечённые сотрудники

M=20 · ½ базы

2,65 млн ₽

PV масштабируется с M при тех же h и a.
Фактический охват определит обследование.

Время PM и проверки

$\Delta PV = -2{,}283 \times C_{review}$

−2,283 ₽ PV

На 1 ₽ ежегодных затрат на ревью.
Дисконтирование за три года.

Задержка запуска

$B_1=0$ · $B_2=B_3=B$

3,28 млн ₽

Первый год без эффекта, дальше полный.
Горизонт остаётся три года.

Ручной VoC	Rule-based pipeline	RequestFlow
Время аналитиков и качество отбора	Покрытие правил и затраты сопровождения	Дополнительный эффект над лучшей альтернативой

ПРИЛОЖЕНИЕ 2 ПРОКСИ-МЕТРИКИ РАННЕГО ПИЛОТА

Как измерить пользу RequestFlow до накопления продуктовой статистики

Два ранних индикатора качества и операционного эффекта

01 / КАЧЕСТВО ДОКАЗАТЕЛЬСТВ

Evidence-Ready Rate

```
ERR = N_ready / N_review × 100%
```

N_ready — карточки, прошедшие все проверки.
N_review — все кандидаты, переданные на проверку за период, включая отклонённые до ревью PM.

Карточка проходит проверку, если соблюдены пять условий

01 Действующий source_id у каждого факта
02 Доступ проверяющего к источнику по ACL
03 Наблюдение отделено от гипотезы
04 JSON соответствует схеме
05 Критических нарушений политики данных нет

СИНТЕТИЧЕСКАЯ ИЛЛЮСТРАЦИЯ · INSIGHT CARD

Факт: кнопка «Далее» не реагирует. Источник: source_id EXAMPLE-01.
Проверка: ACL разрешён, JSON валиден, гипотеза вынесена отдельно.

Считаем с первой недели по продуктам. Ведём журнал недоступных источников и причин отказа. Полезность сверяем с решениями PM.

02 / ОПЕРАЦИОННЫЙ ЭФФЕКТ

Net Time Saved per Validated Insight

```
Net Time Saved = T_manual - T_assisted
```

T_manual — трудозатраты на эквивалентный полезный инсайт.
T_assisted — трудозатраты с RequestFlow до того же результата.
Включаем PM review, исправления и дополнительное сопровождение.

СИНТЕТИЧЕСКАЯ ИЛЛЮСТРАЦИЯ · БЕЗ ХРОНОМЕТРАЖА

Вручную	Поиск повторов	Сбор доказательств	Карточка и ревью
RequestFlow	Черновик и источники	PM review	Правки и поддержка

Как измеряем

Берём сопоставимые темы и 2–4 недели замеряем оба процесса в Shadow Mode. Сравниваем результаты равного качества.
Отчёт: медиана, межквартильный размах и N, минуты на принятый инсайт. Денежный эффект подтверждаем отдельно.

Первые недели пилота показывают, готовит ли система доказательные инсайты и экономит ли время специалистов.

ПРИЛОЖЕНИЕ 3 МАКРОЭКОНОМИЧЕСКИЕ ПРЕДПОСЫЛКИ

Экономику RequestFlow оцениваем с учётом инфляции и стоимости капитала

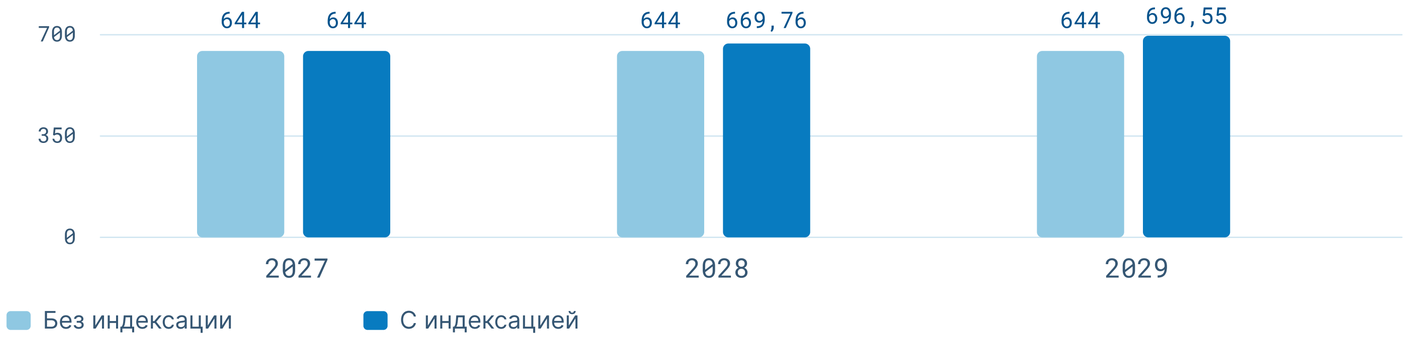
Трёхлетняя модель учитывает индексацию денежных потоков и дисконтирование

БАНК РОССИИ · БАЗОВЫЙ ПРОГНОЗ ИНФЛЯЦИИ НА КОНЕЦ ГОДА

2026	2027	2028	2029
7,1–7,6%	4,0%	4,0%	4,0%

Годовой эффект, тыс. ₽

Сценарий: 644 000 ₽ в первый год · r = 15% · индексация на 4% со второго года



PV_3 · БЕЗ ИНДЕКСАЦИИ	PV_3 · С ИНДЕКСАЦИЕЙ	РАЗНИЦА ИЗ-ЗА ДОПУЩЕНИЯ
1,47 млн ₽	1,52 млн ₽	≈ 54 тыс. ₽

Что меняется в модели

01 Стоимость рабочего времени

Рост оплаты труда повышает стоимость сэкономленных часов. Индексацию зарплат задаём отдельным допущением.

02 Внедрение и сопровождение

Индексируем затронутые расходы на разработку, интеграции, сопровождение и ревью PM. Считаем чистый эффект.

03 Дисконтирование и NPV

Номинальные потоки считаем с номинальной ставкой, реальные — с реальной. 15% — условная ставка модели. Ставку ГПН уточняем.

Инфляция — фактор модели. Показаны две оценки одного эффекта, отдельно от модели для 40 сотрудников.

Инвестиционное решение принимается по чистому дисконтированному эффекту и подтверждённым результатам пилота.

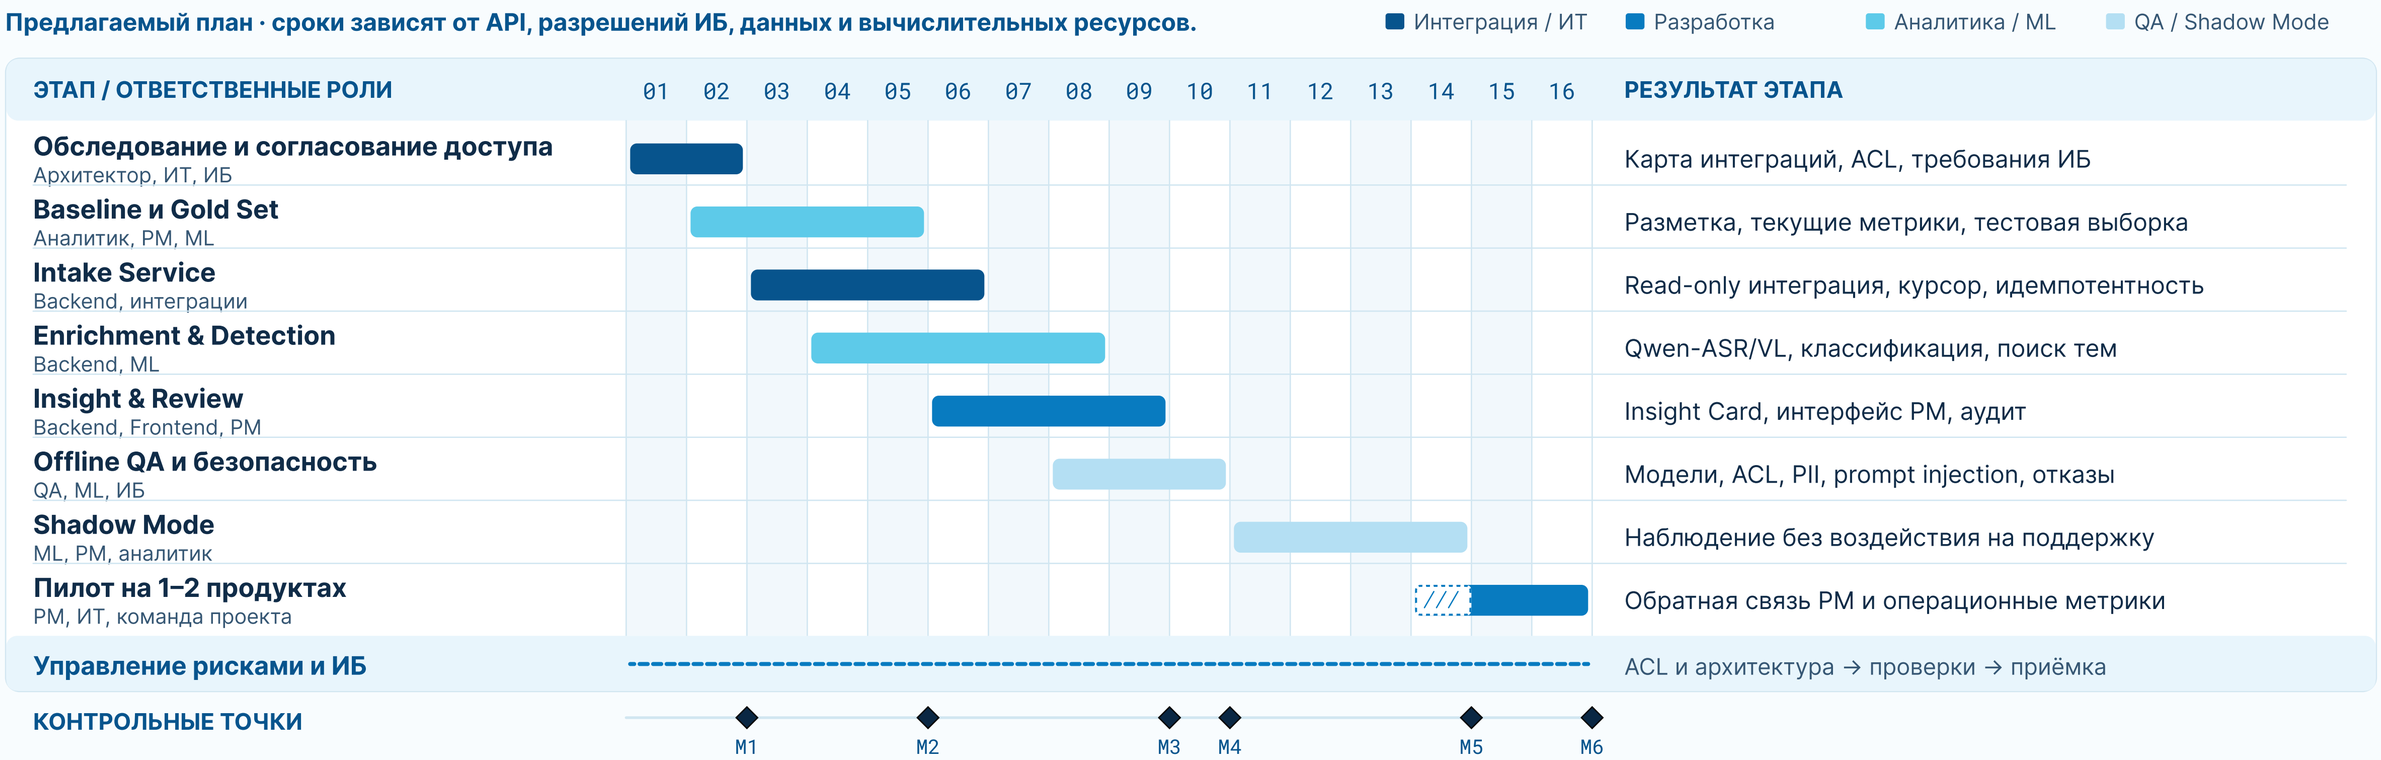
Банк России · прогноз от 05.11.2026 ↗ Банк России · Основные направления ДКП 2027–2029 ↗

ПРИЛОЖЕНИЕ 4 ПЛАН ВНЕДРЕНИЯ

От обследования до пилота: 16-недельный план внедрения

Поэтапная интеграция в инфраструктуру ГПН с контрольными точками безопасности, качества и продуктовой приёмки

Предлагаемый план · сроки зависят от API, разрешений ИБ, данных и вычислительных ресурсов.



M1 / 02 **Контур и доступ согласованы**	M2 / 05 **Gold Set и baseline готовы**	M3 / 09 **Сквозной MVP работает**	M4 / 10 **QA и ИБ готовы к Shadow Mode**	M5 / 14 **Оценка Shadow Mode завершена**	M6 / 16 **Go/No-Go по масштабированию**

Доступ → Intake · Gold Set → offline replay · Intake → сквозной QA · Insight & Review → PM review · M4 → Shadow Mode.
Пилот с 14-й недели возможен после обязательных QA и ИБ-проверок и согласования пересечения с Shadow Mode. Иначе старт после M5.

Масштабируем после Go/No-Go по качеству, безопасности, операционному эффекту и решению PM.